

Предиктивное обслуживание промышленного оборудования

Постановка бизнес-задачи, подготовка данных и исследовательский анализ

Выполнила: Любовь Шумилова

Преподаватель: Денис Алексеев

База данных: manufacturing (PostgreSQL 16)

2026

1. Выбранная база данных

Для проекта используется синтетическая реляционная база данных manufacturing, моделирующая деятельность промышленного предприятия и сбор IoT-телеметрии. База восстановлена из архива PostgreSQL и содержит данные об оборудовании, сенсорах, измерениях, производственных операциях, аварийных событиях и ремонтах.

Показатель	Значение
Таблицы в схеме public	35
Машины	96
Сенсоры	304
Показания сенсоров	2 298 611
События оборудования	23 497
События BREAKDOWN	148
Машины с поломками	74
Заявки на обслуживание	148
Период наблюдения	январь-июнь 2025 года

2. Бизнес-задача

Снизить количество незапланированных простоев и связанных с ними затрат за счёт заблаговременного выявления режимов работы оборудования, при которых возрастает вероятность технического отказа.

Практический результат проекта - инструмент поддержки решений для ремонтной службы. Он должен выделять машины с повышенным риском и помогать приоритизировать осмотр или профилактическое обслуживание.

3. Задача машинного обучения

Задача формулируется как бинарная классификация: по значениям IoT-телеметрии, характеристикам машины и доступной истории её эксплуатации определить, произойдёт ли поломка в течение следующих шести часов.

4. Целевая переменная

Значение	Определение
failure_next_6h = 1	После момента прогноза t и не позднее $t + 6$ часов зарегистрировано событие BREAKDOWN.
failure_next_6h = 0	В указанном шестичасовом горизонте событие BREAKDOWN отсутствует.

Моментом прогноза будет окончание часового интервала. Признаки рассчитываются только по сведениям, доступным до этого момента; сведения из будущего не используются.

5. Объясняющие признаки

Группа	Примеры показателей	Практический смысл
Телеметрия за предыдущий час	Среднее, минимум, максимум, стандартное отклонение	Характеризует текущий режим и нестабильность работы
Выходы за диапазон	Количество и доля показаний ниже <code>min_valid_value</code> или выше <code>max_valid_value</code>	Фиксирует потенциально опасные режимы
Оборудование	Тип машины, номинальная мощность, возраст, производственная линия	Учитывает конструктивные и эксплуатационные различия
История событий	Число прошлых поломок, время с последнего отказа	Отражает накопленную аварийность
Обслуживание	Время с последнего ремонта, число недавних обслуживаний	Характеризует актуальность технического состояния

6. Защита от утечки целевой переменной

В признаки нельзя включать само будущее событие BREAKDOWN, его продолжительность, заявку на ремонт, созданную после отказа, или показания, полученные после момента прогноза. Иначе модель получит сведения о результате заранее, а метрики будут искусственно завышены.

7. Первичный аудит базы

Аудит выполнен SQL-файлом 01_аудит_базы.sql после восстановления архива в PostgreSQL 16. Проверены объёмы телеметрии, фактические события, допустимые диапазоны и пропуски в ключевых полях.

7.1. Качество телеметрии

Тип сенсора	Показаний	Машин	Диапазон	Вне норматива
HUMIDITY	122 925	15	22,323-68,382	0
POWER	626 666	96	0,260-5,078	0
PRESSURE	64 515	8	61,953-98,719	0
RPM	225 126	28	1 186,123-3 164,118	0
TEMPERATURE	770 517	96	42,162-229,155	126 621 (16,43%)
VIBRATION	488 862	61	-0,043-7,467	1 (<0,001%)

- Пропуски в sensor_id, recorded_at, numeric_value и quality_status отсутствуют.
- Существенные выходы за норматив сосредоточены в температуре: 126 621 из 770 517 показаний, или 16,43%. Это потенциально содержательный сигнал риска, поэтому такие строки нельзя удалять автоматически.
- Для вибрации найдено одно отрицательное значение -0,043 мм/с. Его следует проверить как возможную погрешность измерения и отдельно пометить при очистке.
- По влажности, мощности, давлению и скорости вращения выходов за документированные границы не обнаружено.

7.2. События оборудования

Событие	Количество	Затронуто машин	Использование
STARTUP	7 783	96	Контекст эксплуатации
SHUTDOWN	7 783	96	Контекст эксплуатации
SETUP	7 783	96	Контекст эксплуатации
BREAKDOWN	148	74	Целевое событие
Остальные 4 типа	0	0	Только справочник

- Поломок существенно меньше штатных наблюдений, поэтому при моделировании потребуются хронологическое разбиение с контролем баланса классов и метрики Recall, F1 и PR-AUC, а не только accuracy.

7.3. Итоговое представление для ML

Показатель	Результат
Наблюдения «машина-час»	17 403
Машины	96
failure_next_6h = 1	270 (1,5515%)
failure_next_6h = 0	17 133 (98,4485%)
Период прогнозов	10.01.2025 16:00 - 01.07.2025 00:00, UTC+11

Одна поломка может образовывать несколько положительных строк, поскольку целевая переменная проверяет наличие BREAKDOWN в шестичасовом интервале после каждого часового момента прогноза. Поэтому 270 положительных наблюдений не противоречат 148 зарегистрированным событиям BREAKDOWN.

7.4. Структурные пропуски признаков

Признак	Пропусков	Доля
temperature_avg_1h	0	0,00%
vibration_avg_1h	6 358	36,53%
power_avg_1h	46	0,26%
rpm_avg_1h	12 295	70,65%
pressure_avg_1h	15 895	91,33%
humidity_avg_1h	14 517	83,42%

Большая доля пропусков давления, влажности, RPM и вибрации объясняется тем, что датчики этих типов установлены не на всех машинах. Это структурное отсутствие измерения, а не потеря строки. Удаление таких наблюдений исключило бы значительную часть оборудования. В анализе будут добавлены индикаторы наличия сенсоров, а числовые значения при необходимости будут заполняться медианами внутри типа машины.

8. Соответствие требованиям задания

Требование	Артефакт
Выбор и распаковка базы	PostgreSQL manufacturing
Бизнес- и ML-задача	Разделы 2-3 отчёта
Цель и признаки	Разделы 4-5 отчёта

Требование	Артефакт
Создание VIEW	SQL-файлы 02-03
Выгрузка CSV/XLSX	SQL-файл 04 и файл данных
EDA и графики	Colab-ноутбук
Очистка данных	Colab-ноутбук и отчёт
Гипотезы и выводы	Colab-ноутбук и отчёт

9. Порядок выполнения

Шаг 1. Аудит базы. Выполнить 01_аудит_базы.sql и зафиксировать структуру, объёмы, временной диапазон и целевые события.

Шаг 2. Обогащение телеметрии. Выполнить 02_обогащенное_представление_телеметрии.sql и рассчитать признак выхода за допустимый диапазон.

Шаг 3. Итоговый VIEW. Выполнить 03_итоговое_VIEW_для_ML.sql: агрегировать прошлый час и сформировать failure_next_6h.

Шаг 4. Выгрузка. Выполнить 04_выгрузка_VIEW.sql и экспортировать итоговую выборку.

Шаг 5. Анализ и оформление. Запустить Предиктивное_обслуживание_EDA.ipynb, провести очистку, построить графики, проверить гипотезы и перенести итоговые выводы в отчёт.

10. Результаты исследовательского анализа

Выгрузка содержит 17 403 строки и не имеет дубликатов. Целевой класс `failure_next_6h = 1` представлен 270 наблюдениями (1,5515%), поэтому итоговая выборка несбалансирована.



Рисунок 1. Баланс целевой переменной `failure_next_6h`.

Структурные пропуски не удалялись: для анализа используются доступные показания, а для будущего моделирования создаются индикаторы наличия сенсоров. Единственное отрицательное минимальное значение вибрации заменяется на пропуск без удаления всего наблюдения. Температурные превышения сохраняются как потенциальный сигнал.

10.1. Тип оборудования и риск




Рисунок 2. Доля положительных наблюдений по типам машин.

Наибольшая доля положительных наблюдений отмечена у ROBOT (2,04%), наименьшая у WELDER (0,92%). Различия статистически заметны на исследовательском уровне (критерий хи-квадрат, $p = 0,0194$), но не доказывают причинность.

10.2. Числовые признаки

Сравнение числовых признаков по целевому классу




Рисунок 3. Распределения RPM и вибрации по целевому классу.

Для вибрации заметного разделения классов нет. Медианный RPM перед поломкой ниже: 2 425,8 против 2 471,7 об/мин. Эффект требует проверки внутри типов машин.

10.3. Корреляции




Рисунок 4. Корреляционная матрица выбранных числовых признаков.

Линейные корреляции отдельных показателей с целью малы. Вероятная зависимость может проявляться во взаимодействии нескольких признаков или иметь нелинейную форму.

11. Проверка гипотез

Гипотеза	Наблюдаемый результат	Вывод
Н1. Температурное превышение повышает риск	1,54% без превышения; 1,59% с превышением; $p = 0,9048$	Не подтверждена
Н2. Высокая вибрация повышает риск	Медианы 2,506 и 2,506 мм/с; $p = 0,3477$	Не подтверждена
Н3. Снижение RPM связано с риском	Медианы 2 471,7 и 2 425,8 об/мин; $p < 0,001$	Поддерживается данными

Гипотеза	Наблюдаемый результат	Вывод
H4. Риск зависит от типа машины	Диапазон долей 0,92-2,04%; $p = 0,0194$	Поддерживается данными
H5. Прошлая поломка повышает риск	1,40% без истории; 1,71% с историей; $p = 0,1144$	Недостаточно подтверждений

Статистические тесты являются исследовательскими, поскольку последовательные часовые наблюдения одной машины не полностью независимы. Они показывают связь, но не устанавливают причинность. Практически наиболее полезны дальнейшая проверка RPM с учётом типа оборудования и построение моделей, способных учитывать нелинейные взаимодействия. Для оценки модели потребуется хронологическое разделение и метрики Recall, F1 и PR-AUC.